

## Informe de Análisis – PROYECTO 1: Clasificación de “contaminaciones” en una línea de producción simulada

### 1. Introducción

El proyecto se centró en la construcción de un dataset grupal de imágenes procesadas y en la evaluación de modelos clásicos de clasificación. El objetivo fue identificar impurezas en granos de arroz mediante técnicas de aprendizaje automático, aplicando un flujo completo de preprocesamiento, consolidación de datos y entrenamiento de modelos.

---

### 2. Procedimiento de construcción del dataset

- **Captura y mejora de imágenes:** Las fotografías originales se tomaron en condiciones no ideales de iluminación y fondo. Se utilizó *Notebloc Scanner* para mejorar el contraste y obtener un fondo blanco uniforme.
  - **Preprocesamiento:** Conversión a escala de grises, redimensionamiento a 128×128 píxeles y vectorización en matrices binarias.
  - **Consolidación:** Cada imagen se transformó en un vector fila con 16 384 características más una etiqueta de clase (0 = limpio, 1 = impureza).
  - **Dataset final:** Se integraron todas las matrices en un único archivo `matriz_final.csv`, que constituye la base para los experimentos posteriores.
- 

### 3. Modelos evaluados

Se entrenaron y compararon los siguientes algoritmos usando `scikit-learn`:

- Árbol de Decisión
- Naive Bayes
- K-Nearest Neighbors (KNN)
- Support Vector Machine (SVM) con kernel lineal y RBF
- Random Forest

La evaluación se realizó con métricas de **accuracy**, **precision**, **recall** y **f1-score**, utilizando división de datos con `train_test_split`.

---

## 4. Resultados

Los niveles de exactitud obtenidos fueron:

- **SVM Lineal** → 100.00 %
  - Árbol de Decisión → 99.08 %
  - Random Forest → 94.50 %
  - KNN k=3 → 90.83 %
  - KNN k=7 → 87.16 %
  - SVM RBF → 83.49 %
  - Naive Bayes → 77.06 %
  - KNN k=5 → 70.64 %
  - Árbol de Decisión (max\_depth=5) → 66.06 %
- 

## 5. Selección del modelo final

El modelo seleccionado fue el **SVM Lineal**, exportado como `B88639_Alex_Viquez.joblib`. Su elección se justifica por:

- Mayor precisión en el conjunto de prueba.
  - Robustez frente a la alta dimensionalidad del dataset.
  - Mejor generalización en comparación con kernels más complejos.
- 

## 6. Análisis breve

El rendimiento sobresaliente del SVM lineal se explica por:

- **Separabilidad lineal:** Las características del dataset permiten una frontera clara entre clases.
  - **Normalización de datos:** El uso de `StandardScaler` optimizó los márgenes de decisión.
  - **Alta dimensionalidad:** En espacios grandes, los SVM lineales superan a KNN y Naive Bayes, que sufren el “curse of dimensionality”.
  - **Evita sobreajuste:** A diferencia del kernel RBF, el modelo lineal capturó la frontera de decisión sin complejidad innecesaria.
- 

## 7. Limitaciones y mejoras

- Validar con más datos para confirmar la generalización.
- Explorar regularización (parámetro C) para controlar el sobreajuste.

- Mejorar preprocesamiento de imágenes para reducir sombras y variaciones de fondo.
  - Probar arquitecturas más avanzadas (redes neuronales).
- 

## 8. Reproducibilidad

- **Entorno:** Google Colab (CPU estándar).
- **Dependencias:** scikit-learn, numpy, pandas.

|                           |                                                                                                 |
|---------------------------|-------------------------------------------------------------------------------------------------|
| <b>Comando principal:</b> | <pre>from sklearn.svm import SVC model = SVC(kernel='linear') model.fit(X_train, y_train)</pre> |
|---------------------------|-------------------------------------------------------------------------------------------------|

- **Exportación:** `joblib.dump(model, 'B88639_Alex_Viquez.joblib')`
- 

## 9. Acceso al repositorio

<https://github.com/AlexPatricio/Proyecto1-IE0435>

---

## 10. Conclusión

El proyecto demostró que un enfoque clásico como el **SVM lineal** puede alcanzar resultados óptimos en datasets de alta dimensionalidad y buena separabilidad.

---