

Informe de Análisis – PROYECTO 1: Clasificación de “contaminaciones” en una línea de producción simulada

1. Introducción

El proyecto se centró en la construcción de un dataset grupal de imágenes procesadas y en la evaluación de modelos clásicos de clasificación. El objetivo fue identificar impurezas en granos de arroz mediante técnicas de aprendizaje automático, aplicando un flujo completo de preprocesamiento, consolidación de datos y entrenamiento de modelos.

2. Procedimiento de construcción del dataset

- **Captura y mejora de imágenes:** Las fotografías originales se tomaron en condiciones no ideales de iluminación y fondo. Se utilizó *Notebloc Scanner* para mejorar el contraste y obtener un fondo blanco uniforme.
 - **Preprocesamiento:** Conversión a escala de grises, redimensionamiento a 128×128 píxeles y vectorización en matrices binarias.
 - **Consolidación:** Cada imagen se transformó en un vector fila con 16 384 características más una etiqueta de clase (0 = limpio, 1 = impureza).
 - **Dataset final:** Se integraron todas las matrices en un único archivo `matriz_final.csv`, que constituye la base para los experimentos posteriores.
-

3. Modelos evaluados

Se entrenaron y compararon los siguientes algoritmos usando `scikit-learn`:

- Árbol de Decisión
- Naive Bayes
- K-Nearest Neighbors (KNN)
- Support Vector Machine (SVM) con kernel lineal y RBF
- Random Forest

La evaluación se realizó con métricas de **accuracy**, **precision**, **recall** y **f1-score**, utilizando división de datos con `train_test_split`.

4. Resultados

Los niveles de exactitud obtenidos fueron:

- **SVM Lineal** → 100.00 %
 - Árbol de Decisión → 99.08 %
 - Random Forest → 94.50 %
 - KNN k=3 → 90.83 %
 - KNN k=7 → 87.16 %
 - SVM RBF → 83.49 %
 - Naive Bayes → 77.06 %
 - KNN k=5 → 70.64 %
 - Árbol de Decisión (max_depth=5) → 66.06 %
-

5. Selección del modelo final

El modelo seleccionado fue el **SVM Lineal**, exportado como `B88639_Alex_Viquez.joblib`. Su elección se justifica por:

- Mayor precisión en el conjunto de prueba.
 - Robustez frente a la alta dimensionalidad del dataset.
 - Mejor generalización en comparación con kernels más complejos.
-

6. Análisis breve

El rendimiento sobresaliente del SVM lineal se explica por:

- **Separabilidad lineal:** Las características del dataset permiten una frontera clara entre clases.
 - **Normalización de datos:** El uso de `StandardScaler` optimizó los márgenes de decisión.
 - **Alta dimensionalidad:** En espacios grandes, los SVM lineales superan a KNN y Naive Bayes, que sufren el “curse of dimensionality”.
 - **Evita sobreajuste:** A diferencia del kernel RBF, el modelo lineal capturó la frontera de decisión sin complejidad innecesaria.
-

7. Limitaciones y mejoras

- Validar con más datos para confirmar la generalización.
- Explorar regularización (parámetro C) para controlar sobreajuste.

- Mejorar preprocesamiento de imágenes para reducir sombras y variaciones de fondo.
 - Probar arquitecturas más avanzadas (redes neuronales) en futuras entregas.
-

8. Reproducibilidad

- **Entorno:** Google Colab (CPU estándar).
- **Dependencias:** scikit-learn, numpy, pandas.

Comando principal:	<pre>from sklearn.svm import SVC model = SVC(kernel='linear') model.fit(X_train, y_train)</pre>
---------------------------	---

- **Exportación:** `joblib.dump(model, 'B88639-Alex_Viquez.joblib')`
-

9. Acceso al repositorio

<https://github.com/AlexPatricio/Proyecto1-IE0435>

10. Conclusión

El proyecto demostró que un enfoque clásico como el **SVM lineal** puede alcanzar resultados óptimos en datasets de alta dimensionalidad y buena separabilidad.
